第三周机器学习

> 本文公式显示需要使用Mathjax，然后令人悲伤的是github不支持Mathjax 您可以将这篇md文件pull下来，使用您本地的markdown解析器解析 没有必要在公示显示上浪费时间，您也可以下载我本地生成的html用浏览器打开即可 或者您也可以下载我上传到github上的pdf *Mathjax开源项目地址*

个人反馈

这是我学习机器学习第三周,一开始跟着视频老师学习vggnet和resner,发现听不懂,一方面是tensorflow的api函数我没有基础知识,另一方面是神经网络相关的基础知识不够扎实,因此我计划再次回到吴恩达老师的课程中去,吴恩达有一个专讲深度学习的视频,目前学习中....

再谈二分分类

- 对于输入矩阵$X_{n\times m}$的理解:X为n行,m列的矩阵,可以理解为m个n维列向量,**n即代表单个输入向量的特征数,m即代表输入样本个数**,此时对于二分分类下的输出Y来说,Y是一个向量,维度为m.这里吴恩达老师将其定义为列向量,即Y表示为$Y_{1\times m}$
- 关于logistic function 中 sigmoid(z)的z的表示有两种表示方法:
  - w^Tx+b
  - θ^Tx
- cost function 这里不使用误差平方作为cost function的原因是:该函数不是一个凸函数,即存在局部最值 我们将loss(error) function选用

我们将 cost function 定义为:

cost function的简单推导

我们令

合并写法

由于log是单调递增函数,因此我们可以用log(P)代替P,所以有

这里我们根据极大似然估计的思想,假设m个训练样本iid
那么有

我们为了让极大似然函数取最大,那么我们应该使得$\sum_{i=1}^{m}\log(P(y(i)|x(i)))$值要大一些,即loss function的累加值要小一些,从而我们定义 cost function:

这也就证实了cost function计算出来的值越小越好.

Computation Graph and Derivatives

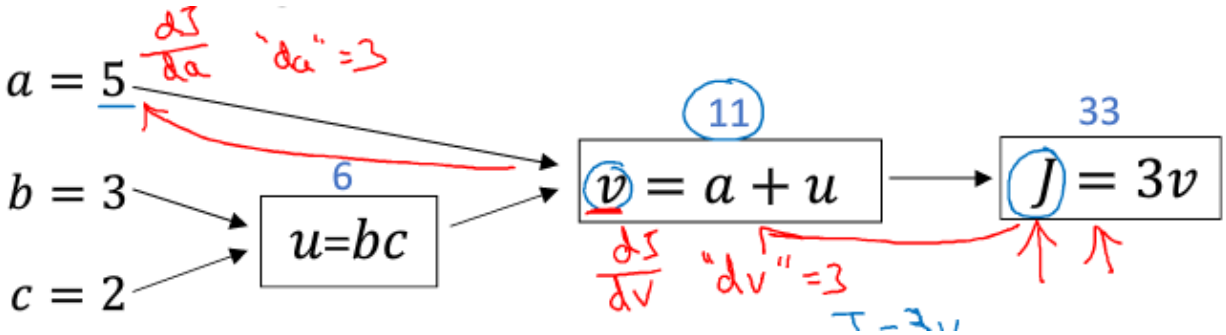

其实计算图的出现是为了让我们更好的理解求偏导的过程:即复合函数求导(链式法则),进而为Backpropagation打下基础

Node:

> 编程习惯:变量da表示$\frac{\partial J}{\partial a}$ 在使用numpy定义向量时,不要使用1维的array表示向量,而是使用nx1的矩阵 举例: a = np.random.randn(5) # X
> a = np.random.randn((5,1)) # √

向量化

向量化的作用就是采用向量或者矩阵相乘的形式来代替for循环,从而加快运算速度. 但是GPU和CPU都含有并行化指令有时也叫SIMD（single instruction multiple data）指令。如果你使用这样的内置函数np.dot 或者np.functions,或者其它能让你去掉显式for循环的函数，这样python的numpy能够充分利用并行化能更加快速的计算这点对GPU和CPU上面计算都是成立的,GPU更加擅长SIMD计算但是CPU实际上也不差，只是没有GPU擅长而已。 实际编程的法则是只要有可能就不能显式的使用for循环。

再谈神经网络

一些符号定义和命名

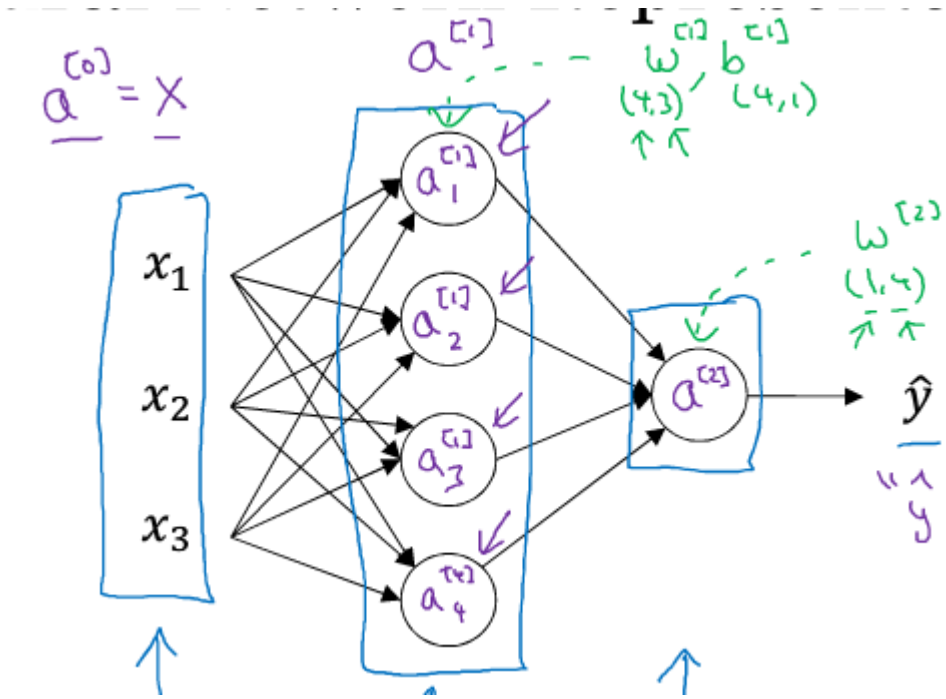

在我们计算神经网络的层数时候,一般不包含输入层,因此上图给出的是一个2 Layer NN

这里定义一些符号

下面一单个样本为例,展示各个向量之间的计算关系,这里采用w与 b来表示变量之间的线性关系

根据logistic regression中的基本关系式
sigma函数可以看做一个activation function

我们以输入层到隐藏层为例,这里我们先不着急立马写出矩阵形式的表达式 先给出w的形式

即

这里需要注意的$\vec{w}_i^{[i]}$是一个三维的列向量,下面我们对上述过程进行向量化

同理,我们可以得出输出层与隐藏层的关系,这里需要注意的矩阵和向量的维度

多个样本时的向量化

这里我们将m个样本定义为

这里我们设 $A^{[0]} = X_{n\times m}$,由此我们推导$A^{[0]}$ 与 $A^{[1]}$的关系
对于任意网络,设当前层的神经元个数为L_i,设n为上一层神经元的个数 那么有

Activation function

Q:如果activation function是线性的会怎样?
如果神经网络的各个层之间都是某个线性函数作为activation function,那么最终的输出与输入之间就化简为简单的线性关系,这样对于模型的拟合程度和简单线性回归没有任何区别,因此就需要activation function为非线性的.
设activation fucntion为$a = g(z)$

1. sigmoid function sigmiod:

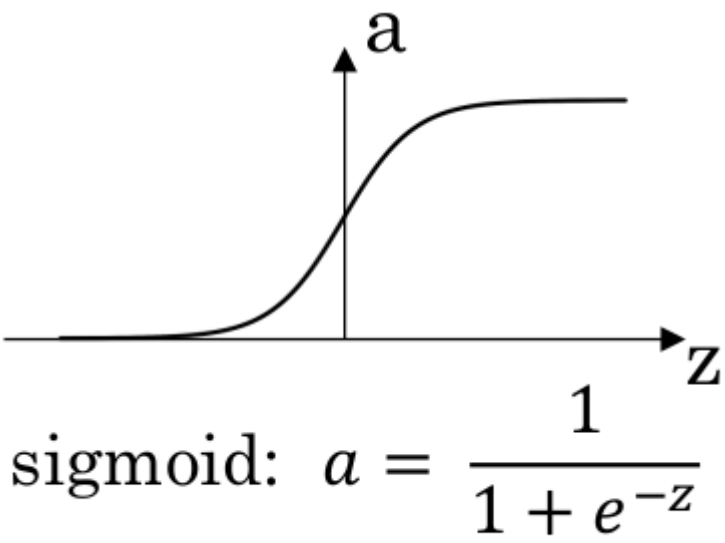

2. tanh

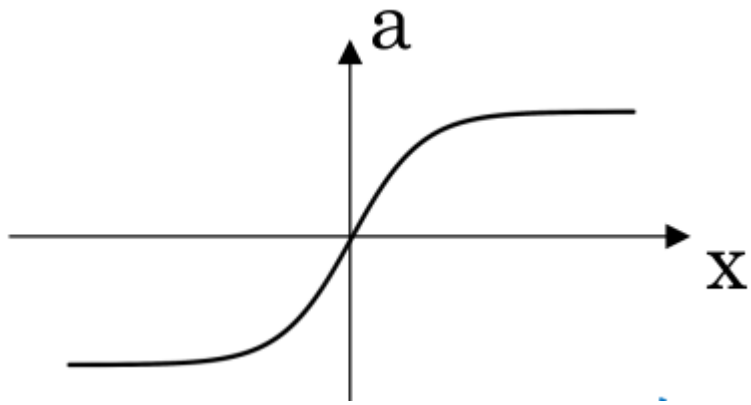

the mean of the data is close to zero,thie actually makes learning for the next layer a little bit easier.
在隐藏层中一般使用tanh function代替sigmoid function.
在输出层,若希望 $\hat{y} \in [0,1]$,那么仍然用sigmoid function

3. Relu function(首选)

$$
```
a = relu(z) = \max(0,z)
```
$$

$$a = relu(z) = \max(0, z)$$

无论是sigmoid function还是tanh function,都有一个缺点:当z非常小的时候,函数斜率就会变得非常小,这样就会拖慢梯度下降,ReLU没有斜率接近于0的情况,尽管当z<0时,ReLU的斜率为0,但是在实践中,有足够多的隐藏单元令z>0

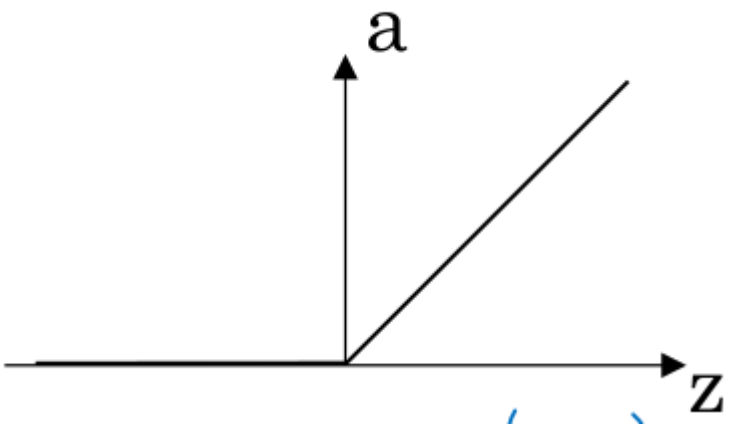

4 leaky Relu